

Метрики и артефакты Super-Resolution


Иван Молодецких
Video Group
CS MSU Graphics&Media Lab

Содержание

- **Артефакты SR**
- Метрики качества SR
- Детекция и устранение артефактов

Артефакты Super-Resolution

В настоящее время для задачи SR используются преимущественно нейросетевые методы. Главным плюсом таких методов является более точное восстановление текстур, мелких деталей.



Кадр из видео, увеличенного
бикубиком



Кадр из видео, увеличенного
RealESRGAN

Артефакты Super-Resolution

На практике из этого вытекает и их главный минус: часто они могут дорисовывать детали, которые не предполагались изначальном изображении, или просто исказить текстуру, цвет и т.д.



Бикубик




RealESRGAN

Пример, когда нейросеть дорисовывает ненужные детали

Артефакты Super-Resolution

Артефакты – искажающие восприятие особенности, странности, которых не было на исходном изображении, но которые появились в результате его обработки.

Часто их можно увидеть в современных телевизорах со встроенными методами SR



Бикубик




RealSR


Пример, когда нейросеть искажает текстуру и цвет

Артефакты Super-Resolution

Добавление объектов (1)



Bicubic



GFPAN

Артефакты Super-Resolution

Добавление объектов (2)



Bicubic

GFPGAN

Артефакты Super-Resolution

Искажение лиц (1)



Bicubic



SwinIR

Артефакты Super-Resolution

Искажение лиц (2)




Оригинал

Bicubic

GFPGAN

Артефакты Super-Resolution

Искажение лиц (3)



Real-ESRGAN

Артефакты Super-Resolution

Искажение текстур (1)



Original



Bicubic, x4



SwinIR, x4



Артефакты Super-Resolution

Искажение текстур (2)



Bicubic



RealSR

Артефакты Super-Resolution

Галлюцинации текстур



Original



Bicubic, x4



RealESRGAN, x4

Артефакты Super-Resolution

Даже если SR восстанавливает качественное изображение, оно может не соответствовать оригиналу



RealBasicVSR

Оригинал

Артефакты Super-Resolution

Например, зачастую не удаётся корректно восстановить лицо человека



RealBasicVSR

Оригинал

Артефакты Super-Resolution

Например, зачастую не удаётся корректно восстановить лицо человека



Оригинал



Clarity AI

Артефакты Super-Resolution



Input
From real life

DFDNet
ECCV 20

Wan *et al.*
CVPR 20

PULSE
CVPR 20

GFP-GAN
Ours

Артефакты Super-Resolution




Оригинал



PULSE

Артефакты Super-Resolution



Содержание

- Артефакты SR
- **Метрики качества SR**
 - PieAPP
 - Q-Align
- Детекция и устранение артефактов

Почему обычные метрики не справляются с задачей SR



- Традиционные FR метрики качества (**PSNR, SSIM, MSE**) слишком просты, чтобы уловить сложные искажения, в том числе часто происходящие сдвиги пикселей
- NR метрика **NIQE** также не способна уловить артефакты SR, так как они неестественны
- Подобных артефактов **нет в UGC и PGC датасетах, авторы метрик обычно не учитывают возможность их появления**. Поэтому даже современные нейросетевые метрики часто не могут корректно оценить видео и изображения со специфическими для SR артефактами

Бенчмарк метрик SR

Основные цели исследований в данной области:

- найти как можно больше кейсов, на которых ошибаются метрики;
- научиться воспроизводить их в наших датасетах SR;
- найти способы преодолеть подобные ошибки метрик.

PaQ-2-PiQ↑: 56.518




PaQ-2-PiQ↑: 67.859



Почему обычные метрики не справляются с задачей SR

Современные SOTA IQA и VQA метрики неспособны корректно оценить результат работы SR



Лидерборд бенчмарка метрик SR на PapersWithCode

Почему обычные метрики не справляются с задачей SR

Было найдено много кейсов, на которых ломаются метрики при оценке SR. Чаще всего это **повышенная резкость, джиттер и большое количество мелких деталей** (последнее связано с тем, что метрики обычно понижают разрешение кадров)

HyperIQA↑: 0.330



HyperIQA↑: 0.341



Пример, когда метрике “нравится” менее детализированное видео

Почему обычные метрики не справляются с задачей SR



Rank ▲	Name	Full Dataset ⚡	SR Dataset ⚡	SR+Codecs ⚡	VSR Benchmark ⚡	VUB Benchmark ⚡	FPS ⚡
1	Subjective Score	1.00000	1.00000	1.00000	1.00000	1.00000	2000.00
2	PieAPP (FR; over RGB)	<u>0.78677</u>	<u>0.87964</u>	<u>0.84282</u>	0.68968	0.73495	1.03
3	Q-Align (Image; NR; over RGB)	0.75088	0.84800	0.80598	0.58568	0.76385	1.91
4	PaQ-2-PiQ (NR; over RGB)	0.74203	0.86313	0.77035	0.55876	<u>0.77589</u>	17.36
5	Q-Align (Video; NR; over RGB)	0.71812	0.80155	0.76027	0.56574	0.74492	2.48
6	MANIQA (NR; over RGB)	0.71502	0.79132	0.77599	0.55700	0.73577	4.07
7	MUSIQ trained on PaQ-2-PiQ (NR; over RGB)	0.70171	0.76432	0.77987	0.50243	0.76023	15.87
8	ClipIQA+ (NR; over RGB)	0.69774	0.78771	0.81938	0.51512	0.66873	13.9
9	Linearity (NR; over RGB)	0.68564	0.80362	0.75481	0.43113	0.75301	15.25

Лидерборд бенчмарка метрик SR

Оценка на полном датасете – среднее из оценок на всех датасетах

Почему обычные метрики не справляются с задачей SR



Рассмотрим некоторые популярные IQA метрики и их работу с артефактами SR (в скобках указаны их места в лидерборде бенчмарка метрик SR)


- **PaQ-2-PiQ** (3 место на полном датасете; 1 место на датасете бенчмарка Video Upscalers);
- **MUSIQ** (7 место на полном датасете; 2 место на датасете бенчмарка Video Upscalers);
- **HyperIQA** (30 место на полном датасете; 17 место на датасете бенчмарка Video Upscalers).

Почему обычные метрики не справляются с задачей SR

На примере ниже популярные IQA метрики предпочитают очень сильно искажённое видео

PaQ-2-PiQ↑: 56.896
HyperIQA↑: 0.287
MUSIQ↑: 30.596

PaQ-2-PiQ↑: 58.564
HyperIQA↑: 0.328
MUSIQ↑: 35.054



Почему обычные метрики не справляются с задачей SR

Скорее всего это связано с сильной стилизацией, превратившей видео в анимацию, а также с почти полной потерей деталей, воспринимаемых как шум

PaQ-2-PiQ↑: 56.896


HyperIQA↑: 0.287

MUSIQ↑: 30.596

PaQ-2-PiQ↑: 58.564

HyperIQA↑: 0.328

MUSIQ↑: 35.054




Почему обычные метрики не справляются с задачей SR

На примере ниже PaQ-2-PiQ почти одинаково оценивает изображение хорошего качества и изображение с сильным искажением

PaQ-2-PiQ↑: 75.880



PaQ-2-PiQ↑: 72.033




Почему обычные метрики не справляются с задачей SR

Причины, вероятно, те же самые. Также датасет, на котором обучался PaQ-2-PiQ (AVA) не содержит никаких синтетических искажений

PaQ-2-PiQ $\uparrow$: 75.880



PaQ-2-PiQ $\uparrow$: 72.033



Метрики из топа бенчмарка

Теперь рассмотрим метрики, занимающие первые два места в лидерборде бенчмарка метрик SR

- **PieAPP** (1 место на полном датасете)
- **Q-Align** (2 место на полном датасете)

Метрики из топа бенчмарка

PieAPP (1)

Основные идеи:

- используем попарное обучение (что делает процесс оценки качества изображение максимально похожим на процесс субъективного сравнения по модели Брэдли-Терри)




Иллюстрация работы фреймворка из оригинальной статьи

E. Prashnani et al., "PieAPP: Perceptual Image-Error Assessment through Pairwise Preference," in CVPR, 2018

Метрики из топа бенчмарка

PieAPP (2)



Модель Брэдли-Терри:

- $p(i\text{-я картинка лучше } j\text{-й}) = \frac{\gamma_i}{\gamma_i + \gamma_j}$
- $\square_i$ – в общем случае – оценка i -го изображения (можно взять количество людей, которые предпочли i -е изображение j -му при сравнении этих двух изображений)
- $\square_j$ – в общем случае – оценка j -го изображения (можно взять количество людей, которые предпочли j -е изображение i -му при сравнении этих двух изображений)

E. Prashnani et al., "PieAPP: Perceptual Image-Error Assessment through Pairwise Preference," in CVPR, 2018

Метрики из топа бенчмарка

PieAPP (3)

Модель Брэдли-Терри:


- Можем параметризовать $\square_i = e^{s_i}$
- s_i – оценка i -го изображения
- Тогда $p(i\text{-я картинка лучше } j\text{-й}) = \frac{1}{1 + e^{s_j - s_i}}$

Метрики из топа бенчмарка

PieAPP (4)

Если есть оценки каждого из изображений A и B, то в качестве вероятности того, что изображение A лучше B, можно взять сигмоиду от разности оценок A и B

$$p_{AB} = h(s_A, s_B) = \frac{1}{1 + e^{s_A - s_B}}$$




E. Prashnani et al., "PieAPP: Perceptual Image-Error Assessment through Pairwise Preference," in CVPR, 2018

Метрики из топа бенчмарка

PieAPP (5)

Это то же, что и модель Брэдли-Терри, но степень экспоненты инвертирована, чтобы меньшие значения p соответствовали более визуально похожим парам изображений

$$p_{AB} = h(s_A, s_B) = \frac{1}{1 + e^{s_A - s_B}}$$



E. Prashnani et al., "PieAPP: Perceptual Image-Error Assessment through Pairwise Preference," in CVPR, 2018

Метрики из топа бенчмарка

PieAPP (6)



Основные идеи:


- обучение на большом количестве искажений (75 различных искажений, включая SR).

Dataset	Ref. images	Distortions	Distorted images
LIVE [47]	29	5	779
CSIQ [26]	30	6	866
TID2008 [43]	25	17	1,700
TID2013 [42]	25	24	3,000
Our dataset	200	75	20,280

Сравнение датасета PieAPP с другими актуальными на момент написания статьи датасетами

Метрики из топа бенчмарка


PieAPP (7)



- Архитектура: три подсети, в каждой из которых по 11 свёрточных слоёв (фильтры 3x3 + ReLU)
- После каждого чётного слоя – max pooling 2x2
- m – номер патча изображения

Метрики из топа бенчмарка

PieAPP (8)



- Подсеть для подсчёта score состоит из двух полносвязных слоёв: один – для оценок патчей, второй – для весов патчей
- Финальная оценка – взвешенное среднее арифметическое по всем патчам
- R – патч референсного изображения, A – искажённого

Метрики из топа бенчмарка

Q-Align (1)



Основные идеи:

- использовать для оценки изображений Large Multi-Modal модель **mPLUG-Owl2** (в её основе – LLaMa-2-7B);
- обучаем одновременно для задач **Image и Video Quality Assessment**, а также **Image Aesthetic Assessment**.

Метрики из топа бенчмарка


Q-Align (2)

Просим модель оценить качество изображения, предсказывая вероятности того, что оно *bad*, *poor*, *fair*, *good* или *excellent*



Метрики из топа бенчмарка

Q-Align (3)



LLaMa-2-7B (контекст – 2048 чисел, размер эмбединга изображения: 64 $\Rightarrow$ можем работать с видео до 30 кадров)

ViT-L

Метрики из топа бенчмарка

Q-Align (4)



Метрики из топа бенчмарка

Q-Align (5)



- Датасеты для обучения:
 - Image Quality Assessment: **KonIQ, SPAQ, KADID**
 - Video Quality Assessment: **LSVQ**
 - Image Aesthetic Assessment: **AVA**
- Обучение происходило на всех датасетах для всех задач одновременно

Метрики из топа бенчмарка

Q-Align (6)

- Такой подход оказался наиболее удачным

IQA датасеты

<i>Training / Testing Set</i>	KonIQ	SPAQ	KADID	LIVE-C	AGIQA	LIVE	CSIQ
IQA ^(KonIQ + SPAQ + KADID)	.938/.945	.931/.933	.934/.935	.883/.887	.733/.788	.870/.840	.845/.876
VQA ^(LSVQ)	.731/.788	.841/.819	.659/.651	.715/.727	.780/.834	.826/.797	.755/.814
IAA ^(AVA)	.574/.603	.662/.653	.536/.547	.685/.636	.750/.792	.770/.740	.527/.596
IQA + VQA	.944/.949	.931/.934	.952/.953	.892/.899	.739/.782	.874/.846	.852/.876
IQA + IAA	.940/.947	.931/.933	.945/.945	.862/.868	.782/.824	.895/.864	.865/.883
IAA + VQA	.640/.664	.740/.732	.626/.632	.703/.669	.769/.819	.794/.769	.558/.628
All (ONEALIGN)	.941/.950	.932/.935	.941/.942	.881/.894	.801/.838	.887/.856	.881/.906

Метрики из топа бенчмарка

Q-Align (7)

- Такой подход оказался наиболее удачным

	IAA датасет		VQA датасеты		
<i>Training / Testing Set</i>	AVA	LSVQ_{test}	LSVQ_{1080P}	KoNViD	MaxWell
<i>IQA^(KonIQ + SPAQ + KADID)</i>	.208/.228	.755/.757	.680/.718	.799/.806	.682/.694
<i>VQA^(LSVQ)</i>	.289/.323	.883/.882	.797/.830	.865/.877	.780/.782
<i>IAA^(AVA)</i>	.822/.817	.624/.600	.515/.511	.717/.681	.659/.648
<i>IQA + VQA</i>	.197/.222	.885/.883	.802/.829	.867/.880	.781/.787
<i>IQA + IAA</i>	.822/.819	.785/.785	.700/.730	.831/.829	.716/.728
<i>IAA + VQA</i>	.822/.819	.886/.885	.800/.834	.874/.884	.776/.781
<i>All (ONEALIGN)</i>	.823/.819	.886/.886	.803/.837	.876/.888	.781/.786

Метрики из топа бенчмарка

Q-Align (8)



- Итог: метрика стала SOTA на 12 различных датасетах

Training Set: KonIQ _{train}	→Testing Set:	KonIQ _{test}		SPAQ ^{CROSS}		LIVE Challenge ^{CROSS}		AGIQA-3K ^{CROSS}		KADID-10k ^{CROSS}	
Method	#Training	SRCC	PLCC	SRCC	PLCC	SRCC	PLCC	SRCC	PLCC	SRCC	PLCC
NIMA (TIP 2018)	7K (70%)	0.859	0.896	0.856	0.838	0.771	0.814	0.654	0.715	0.535	0.532
DBCNN (TCSVT 2020)	7K (70%)	0.875	0.884	0.806	0.812	0.755	0.773	0.641	0.730	0.484	0.497
HyperIQA (CVPR 2020)	7K (70%)	0.906	0.917	0.788	0.791	0.749	0.772	0.640	0.702	0.468	0.506
MUSIQ (ICCV 2021)	7K (70%)	<u>0.929</u>	<u>0.924</u>	0.863	<u>0.868</u>	0.830	0.789	0.630	0.722	0.556	0.575
CLIP-IQA+ (AAAI 2023)	7K (70%)	0.895	0.909	0.864	0.866	0.805	0.832	0.685	0.736	0.654	0.653
LIQE (CVPR 2023)	7K (70%)	0.928	0.912	0.833	0.846	0.870	0.830	0.708	<u>0.772</u>	<u>0.662</u>	<u>0.667</u>
FEWSHOT-Q-ALIGN (Ours)	2K (20%)	0.903	0.901	<u>0.871</u>	0.860	0.840	<u>0.845</u>	0.740	0.791	0.607	0.589
Q-ALIGN (Ours)	7K (70%)	0.940	0.941	0.887	0.886	<u>0.860</u>	0.853	<u>0.735</u>	<u>0.772</u>	0.684	0.674

Training Set: SPAQ	→Testing Set:	KonIQ _{test} ^{CROSS}		SPAQ		LIVE Challenge ^{CROSS}		AGIQA-3K ^{CROSS}		KADID-10k ^{CROSS}	
Method	#Training	SRCC	PLCC	SRCC	PLCC	SRCC	PLCC	SRCC	PLCC	SRCC	PLCC
NIMA (TIP 2018)	8.8K (80%)	0.733	0.788	0.907	0.910	0.733	0.785	0.534	0.630	0.399	0.480
DBCNN (TCSVT 2020)	8.8K (80%)	0.731	0.758	0.908	0.913	0.702	0.748	0.459	0.518	0.490	0.508
Fang <i>et al.</i> (CVPR 2020)	8.8K (80%)	0.714	0.742	0.908	0.909	0.798	0.762	0.570	0.649	0.381	0.448
MUSIQ (ICCV 2021)	8.8K (80%)	0.753	0.680	0.917	<u>0.921</u>	0.813	0.789	0.564	0.675	0.349	0.429
CLIP-IQA+ (AAAI 2023)	8.8K (80%)	0.753	0.777	0.881	0.883	0.719	0.755	0.577	0.614	0.633	0.638
LIQE (CVPR 2023)	8.8K (80%)	<u>0.826</u>	<u>0.847</u>	<u>0.922</u>	0.919	0.805	<u>0.866</u>	0.672	0.722	0.639	0.627
FEWSHOT-Q-ALIGN (Ours)	2.2K (20%)	0.792	0.826	0.909	0.911	<u>0.823</u>	0.834	<u>0.702</u>	<u>0.772</u>	<u>0.685</u>	<u>0.678</u>
Q-ALIGN (Ours)	8.8K (80%)	0.848	0.879	0.930	0.933	0.865	0.873	0.723	0.786	0.743	0.740

Метрики из топа бенчмарка

Q-Align (9)



- Итог: метрика стала SOTA на 12 различных датасетах

Testing Set:	KonIQ _{test}		SPAQ		KADID-10k		LIVE Challenge		AGIQA-3K		LIVE		CSIQ	
Training Set:	SRCC	PLCC	SRCC	PLCC	SRCC	PLCC	SRCC	PLCC	SRCC	PLCC	SRCC	PLCC	SRCC	PLCC
KonIQ	0.940	0.941	0.887	0.886	0.684	0.674	0.860	0.853	0.735	0.772	0.867	0.838	0.700	0.759
SPAQ	0.848	0.879	0.930	0.933	0.743	0.740	0.865	0.873	0.723	0.786	0.861	0.822	0.733	0.781
KonIQ + SPAQ	0.940	0.943	0.931	0.933	0.708	0.692	0.879	0.883	0.727	0.795	0.859	0.827	0.767	0.795
KADID	0.668	0.665	0.860	0.854	0.919	0.918	0.702	0.744	0.711	0.712	0.809	0.791	0.756	0.784
KonIQ + SPAQ + KADID	0.938	0.945	0.931	0.933	0.934	0.935	0.883	0.887	0.733	0.788	0.870	0.840	0.845	0.876

Метрики из топа бенчмарка

Q-Align (10)



- Итог: метрика стала SOTA на 12 различных датасетах

Training Set: LSVQ _{train}	→Testing Set:	LSVQ _{test}		LSVQ _{1080p}		KoNViD-1k ^{CROSS}		MaxWell _{test} ^{CROSS}	
Method	IQA Pre-training?	SRCC	PLCC	SRCC	PLCC	SRCC	PLCC	SRCC	PLCC
TLVQM (TIP 2019)	✗	0.772	0.774	0.589	0.616	0.732	0.724	–	–
VSFA (ACMMM 2019)	✗	0.801	0.796	0.675	0.704	0.784	0.794	–	–
VIDEVAL (TIP 2021)	✗	0.794	0.783	0.545	0.554	0.751	0.741	–	–
PVQ (CVPR 2021)	✓	0.827	0.828	0.711	0.739	0.791	0.795	0.618	0.634
BVQA (TCSVT 2022)	✓	0.852	0.854	0.772	0.788	0.839	0.830	0.675	0.673
DisCoVQA (TCSVT 2023)	✗	0.859	0.850	0.734	0.772	0.851	0.853	0.704	0.687
SimpleVQA (ACMMM 2022)	✓	0.867	0.861	0.764	0.803	0.840	0.834	0.720	0.715
FAST-VQA (ECCV 2022)	✗	0.876	0.877	0.779	0.814	0.859	0.855	0.720	0.728
Q-ALIGN (Ours) (1fps)	✗	0.883	0.882	0.797	0.830	0.865	0.877	0.780	0.782
— Ensemble-based Approaches									
DOVER (<i>aesthetic branch</i> + FAST-VQA, ICCV 2023)	✗	0.886	0.887	0.795	0.830	0.883	0.884	0.748	0.755
Q-ALIGN (Ours) (1fps) + FAST-VQA	✗	0.899	0.899	0.818	0.850	0.895	0.897	0.779	0.784

Метрики из топа бенчмарка

Q-Align (11)

- Итог: метрика стала SOTA на 12 различных датасетах


<i>Training Set: AVA_{train}</i>		<i>→Testing Set:</i>	<i>AVA_{test}</i>	
Method	#Training	Extra Data?	SRCC	PLCC
NIMA (TIP 2018)	236K (92%)	✗	0.612	0.636
MLSP (CVPR 2019)	236K (92%)	✗	0.756	0.757
MUSIQ (ICCV 2021)	236K (92%)	✗	0.726	0.738
MaxViT (ECCV 2022)	236K (92%)	✗	0.708	0.745
CLIP-IQA+ (AAAI 2023)	236K (92%)	✗	0.619	0.586
Aesthetic Predictor (2023)	236K (92%)	✗	0.721	0.723
LIQE (CVPR 2023)	236K (92%)	✗	0.776	0.763
VILA (CVPR 2023)	236K (92%)	✓	0.774	0.774
FEWSHOT-Q-ALIGN (Ours)	26K (10%)	✗	0.776	0.775
Q-ALIGN (Ours)	236K (92%)	✗	0.822	0.817

Содержание

- Артефакты SR
- Метрики качества SR
- **Детекция и устранение артефактов**


Сбор датасета артефактов SR

- Исходное (GT) изображение уменьшили bicubic-ом в 4 раза
- Затем к полученному (LR) изображению применяем метод повышения разрешения



Датасет артефактов SR

Датасет представляет из себя 4-ку: LR, SR, маску артефакта и вероятность его нахождения



LR

Real-ESRGAN

Маска артефакта

Датасет артефактов SR

В открытой части датасета представлены 202 изображения, полученные различными SOTA SR моделями (SwinIR, Real-ESRGAN, GFPGAN)



GT

SwinSR

Heatmap

Датасет артефактов SR

Артефакты верифицируются на crowdsourcing платформе

Исходное изображение



Результат увеличения



Есть ли искажённые объекты или текстуры в какой-либо части выделенной области на Результате увеличения?
Нажмите на изображение, чтобы увеличить его.

- ☐ 1 На результате увеличения есть искажённые объекты или текстуры
- ☐ 2 Выделенная область не содержит искажённых объектов или текстур
- ☐ 3 Ошибка при загрузке

Датасет артефактов SR

Соотношение ответов “да”/“нет” — сила артефакта



Детекция и устранение артефактов SR. LDL



Основные идеи:


- Строить карту вероятностей того, что пиксель — артефакт
- Добавить к loss-функции GAN-SR'а штраф за артефакт

Детекция и устранение артефактов SR. LDL

Type A



Type B



Type C



I_{SR}


I_{HR}

$|R|$

$$R = I_{HR} - I_{SR}$$

J. Liang et al., "Details or Artifacts: A Locally Discriminative Learning Approach to Realistic Image Super-Resolution," in *CVPR*, 2022

Детекция и устранение артефактов SR. LDL



Исходя из наблюдения, что артефакты чаще всего самые яркие пиксели карты R , можно взять локальную дисперсию карты R в качестве основной карты для детекции пикселей артефактов


$$M(i, j) = var\left(R\left(i - \frac{n-1}{2} : i + \frac{n-1}{2}, j - \frac{n-1}{2} : j + \frac{n-1}{2}\right)\right)$$

$n = 7$

$$M \in \mathbb{R}^{H \times W \times 1}$$

J. Liang et al., "Details or Artifacts: A Locally Discriminative Learning Approach to Realistic Image Super-Resolution," in *CVPR*, 2022

Детекция и устранение артефактов SR. LDL




Локальная дисперсия считается в очень маленьком окне, поэтому она не может стабильно детектировать артефакты на границах и текстурах. По этой же причине может наказываться генерация реалистичных деталей. Чтобы решить эту проблему, считаем дисперсию всей карты R и умножаем на неё карту M .

$$\sigma = (var(R))^{\frac{1}{a}}$$


В ходе экспериментов получено лучшее значение $a = 5$.

Детекция и устранение артефактов SR. LDL


Type A



Type B



Type C



M_{refine}

$|R_1| < |R_2|$

Строим карту артефактов, умножаем на разницу изображений (GT и с повышенным разрешением)

$$M_{\text{refine}}(i, j) = \begin{cases} 0, & \text{if } |R_1(i, j)| < |R_2(i, j)|; \\ \sigma \cdot M(i, j), & \text{if } |R_1(i, j)| \geq |R_2(i, j)|. \end{cases}$$

$$\mathcal{L}_{\text{artif}} = \|M_{\text{refine}} \cdot (I_{\text{HR}} - I_{\text{SR}_1})\|_1$$


$$\mathcal{L}_{\text{GAN}} = \lambda_1 \mathcal{L}_{\text{recons}} + \lambda_2 \mathcal{L}_{\text{percep}} + \lambda_3 \mathcal{L}_{\text{adv}}$$

Добавляем к лоссу штраф за артефакты

$$\mathcal{L}_{\text{LDL}} = \mathcal{L}_{\text{GAN}} + \beta \mathcal{L}_{\text{artif}}$$

J. Liang et al., "Details or Artifacts: A Locally Discriminative Learning Approach to Realistic Image Super-Resolution," in *CVPR*, 2022


Детекция и устранение артефактов SR. LDL



Метод RRDB не выдаёт артефакты, благодаря дообучению с LDL

J. Liang et al., "Details or Artifacts: A Locally Discriminative Learning Approach to Realistic Image Super-Resolution," in *CVPR*, 2022

Детекция и устранение артефактов SR. LDL



Метод RRDB не выдаёт артефакты, благодаря дообучению с LDL

Детекция и устранение артефактов SR. DeSRA


Основные идеи:

- SR'ы, обучающиеся с MSE-лоссом, получаются более размытые, но без артефактов
- Можно генерировать две картинки: MSE SR'ом и GAN SR'ом, а затем заменить область артефакта на эту же область без артефакта с изображения, полученного MSE SR'ом

MSE-SR results




GAN-SR results



L. Xie et al., "DeSRA: Detect and Delete the Artifacts of GAN-based Real-World Super-Resolution Models," on *ICML*, 2023

Детекция и устранение артефактов SR. DeSRA

Строим индикатор артефакта D для каждого семантического класса и объединяем с маской




σ_x – стандартное отклонение интенсивности пикселей в изображении, полученном GAN SR'ом

σ_y – то же самое для изображения, полученного MSE SR'ом

L. Xie et al., "DeSRA: Detect and Delete the Artifacts of GAN-based Real-World Super-Resolution Models," on *ICML*, 2023


Детекция и устранение артефактов SR. DeSRA



L. Xie et al., "DeSRA: Detect and Delete the Artifacts of GAN-based Real-World Super-Resolution Models," on *ICML*, 2023


Детекция и устранение артефактов SR. DeSRA

- Дообучаем SR, используя полученные изображения в качестве GT



L. Xie et al., "DeSRA: Detect and Delete the Artifacts of GAN-based Real-World Super-Resolution Models," on *ICML*, 2023

Детекция и устранение артефактов SR. DeSRA



RealESRGAN




RealESRGAN-DeSRA

Детекция и устранение артефактов SR. DeSRA



RealESRGAN



RealESRGAN-DeSRA

L. Xie et al., "DeSRA: Detect and Delete the Artifacts of GAN-based Real-World Super-Resolution Models," on *ICML*, 2023

Детекция и устранение артефактов SR. DeSRA



LDL



LDL-DeSRA

Заключение

- Современные IQA и VQA метрики зачастую **не способны корректно оценить результат работы методов SR** (даже самый лучший метод на датасете бенчмарка метрик SR показывает корреляцию Спирмена < 0.8)
- Однако появляется всё больше методов, фокусирующихся на корректной оценке изображений с большим числом разнообразных искажений: блюр, шум, джиттер, пространственные искажения, смена цвета, смена резкости (PieAPP, ARNIQA, QualiCLIP)
- Также развивается область детекции и устранения артефактов SR; полученные методы позволяют генерировать более корректные результаты