

Задачи оценки движения и вычисления оптического потока

Ватолин Дмитрий Сергеевич
Video Group
CS MSU Graphics&Media Lab

Характеристики видеопотока

Видеопоток и его характеристики


Видеопоток характеризуется

- разрешением
- частотой кадров (frames per second = fps)
- системой представления цветов
- глубиной цвета

Разрешение видеопотока

- **Разрешение** - количество пикселей по горизонтали и вертикали
 - o NTSC – 720×480
 - o PAL – 720×576
 - o SECAM – 640×480
 - o 25 fps — телевизионные стандарты
 - o 720p, 1080p, QHD, 4K – популярные разрешения цифрового видео

Сравнение разрешений



Наглядное сравнение популярных разрешений

Частота кадров видеопотока

- **Частота кадров** – количество кадров в секунду (FPS)
 - 24 FPS – общемировой стандарт частоты
 - 23.976 FPS – стандарт NTSC
 - 25 FPS – стандарт PAL, SECAM
 - 30 FPS, 60 FPS – популярные частоты записи на любительских устройствах
 - 120 FPS, 240 FPS - популярные частоты записи замедленной съемки

Смена кадров при различном FPS



12 FPS



6 FPS




3 FPS

Плавность смены кадров в зависимости от частоты

Цветовые пространства видеопотока


- **Цветовое пространство** – модель представления цвета, основанная на использовании цветовых координат
 - RGB – базовые цветовые компоненты: красный, зеленый, синий
 - YUV - базовые цветовые компоненты: яркость, хроматический синий и хроматический красный



Кадр, закодированный в
RGB и YUV


Глубина цвета видеопотока

- **Глубина цвета** — количество бит, используемое для хранения и представления цвета
 - 6 бит – 262 тыс. цветов
 - 8 бит (SDR) – 16,7 млн.
 - 10 бит (HDR) – 1,07 млрд.



Градиенты цветов

Недостаточная битность



Артефакты недостаточной битности
слева – 6 бит, справа – 8 бит


Сжатие видео

Стандарт сжатия и кодек

- **Стандарт сжатия** — набор правил и соглашений, которые описывают базовые принципы выбранного подхода к сжатию
- **Кодек** — программная или аппаратная реализация конкретного стандарта сжатия, состоящая из
 - **кодировщика**, отвечающего за сжатие видео
 - **декодировщика**, отвечающего за воссоздание исходного видео с целью его проигрывания

Ожидания от стандартов сжатия видео

Estimated bitrate for high quality FullHD (1080p) content




Битрейт при одинаковом уровне визуального качества
закодированного видео

D. Karwowski, et al., "20 years of progress in video compression—from MPEG-1 to MPEG-h HEVC.," in IP&C, 2017

Реальный прогресс сжатия видео

VVC codecs superiority in MSU Codec Comparison 2021

https://compression.ru/video/codec_comparison/2021



Сжатие видеопотока

- Используется избыточность:
 - **Пространственная** ($\Rightarrow$ используется DCT или Wavelet преобразования)
 - **Временная** (между кадрами $\Rightarrow$ сжимается межкадровая разница)
 - **Цветового пространства** ($\Rightarrow$ RGB переводится в YUV и цветовые компоненты прореживаются)


Избыточность для соседних кадров



Соседние кадры
фильма (Kingsman)

- **Пространственная избыточность** — цвет большинства соседних точек одинаков
- **Временная избыточность** — кадры весьма похожи

Межкадровая разница



- Именно такие кадры (с учетом поправки на компенсацию движения) и сжимает кодек
- Их больше 99% в потоке (амплитуды малы, изображение практически однородно)

Избыточность для соседних кадров




Соседние кадры
фильма
"Терминатор-2"

Межкадровая разница



Структура видеопотока


Типы кадров в потоке



- I-кадры — независимо сжатые (I-Intrapictures)
- P-кадры — сжатые с использованием ссылки на одно предыдущее изображение (P-Predicted)
- B-кадры — сжатые с использованием ссылки на два изображения (B-Bidirection)


Статическая GOP структура MPEG-2 1994 г. (1)

- Статическая GOP структура описывается двумя значениями M — расстояние между I-кадрами, и N — количество B-кадров между I- или P-кадрами



GOP структура от различных N

Статическая GOP структура MPEG-2 1994 г. (2)




GOP структура 15,3 с относительными размерами разных типов кадров

Динамическая GOP структура


H.264 2003 г.

- В семействе кодеков H.264 используют динамическую GOP структуру
- I-кадры – смены сцен
- Расстояние между P-кадрами составляет 8 кадров
- B-кадры не обязательно ссылаются только на I-/P-кадры



Компенсация движения

Схема простого видеокодека




Компенсация движения

- Простая межкадровая разница работает плохо при сильном движении в кадре
- Алгоритмы компенсации движения отслеживают движение объектов в кадре
 - Уменьшение межкадровой разницы (увеличение ее степени сжатия)
 - Необходимость сохранения информации о движении в кадре
 - Существенно большее время, необходимое для сжатия

Вклад компенсации движения




Без компенсации









С компенсацией

Постановка задачи компенсации движения

- **ME (Motion Estimation)** — компенсация движения
- Кадры видео делятся на прямоугольные блоки одинакового размера
- Задача: для каждого блока найти вектор смещения относительно другого кадра, минимизирующий попиксельную разницу



Тема компенсации движения — велика



Метрика блоков

Расстояние между блоками ищется как сумма модулей разности значений пикселов:

$$R(A, B) = \sum_{i=0, j=0}^{n, n} |a_{i,j} - b_{i,j}|$$



Достоинство:

- Хорошо оптимизируется (важно, поскольку ME самая долгая операция при сжатии)

Недостатки:

- Неустойчива к шуму
- Не учитывает изменения яркости


Визуализации функции ошибки (1)



Величина ошибки от (x,y) .

- Взят более-менее типичный блок, сдвинувшийся на 2 пикселя в сравнительно ровной области (стена)
- На левом рисунке – исходный блок, на правом – он же, но по границе 1000 обрезанный сверху



Визуализации функции ошибки (2)



Тот же блок, обрезанный по границе 200 в двух ракурсах


- Хорошо видно, как много у этой функции (казавшейся на первом рисунке гладкой) локальных минимумов
- Если алгоритм будет выбирать их, то блоки начнут «гулять»

Визуализации функции ошибки (3)



- Слева — блок, сдвинувшийся на 6 пикселей по одной оси и на 11 по другой, однако локальных минимумов у графика много
- Справа — также сильно сдвинувшийся блок, но минимум явно виден
- «Ровный» график у дальней стенки — граница изображения

Распределение ошибки



Значение PSNR: 30.5694

Скомпенсированный кадр 24



Кадр 24



Значение PSNR: 37.4670

Значение PSNR: 34.6123

Скомпенсированный кадр 1



Кадр 1



Скомпенсированный кадр 60




Кадр 60



Трудности


- Шумы: блоки не сопоставляются с нужными
- Однотонные поверхности или текстуры: блоки хорошо сопоставляются с ненужными
- Области открытия: нужного блока нет



Отсутствие текстуры



Области открытия





Ошибка в области открытия

Разбиение кадра на блоки


Пирамида разрешений (1)

Уменьшенные версии кадра легче сопоставлять, потому что в блок попадает больше крупных деталей


1. Сделаем несколько уменьшенных версий кадра
2. Сопоставим блоки на самом маленьком разрешении
3. Уточним найденные блоки на большем разрешении
4. Повторим шаг 3, пока не дойдём до исходного кадра




Пирамида разрешений (2)



Разбиение блоков



AV1



VVC

Стратегии поиска оптимального блока

Задача поиска оптимального блока



Задача: за минимальное число замеров найти минимум

Используются комбинации стратегий:



- Cross поиск
- Ортогональный поиск
- Трехшаговый поиск (TSS)
- Четырехшаговый поиск (FSS)

Базовые стратегии поиска (1)


Cross поиск

Шаблон уменьшается на каждом шаге

Шаблон:



Шаблоны:





Базовые стратегии поиска (3)

Three Step Search (TSS)

На каждом шаге
размер шаблона
уменьшается

Шаблон:





Базовые стратегии поиска (4)

Four Step Search (FSS)

Шаблон

не уменьшается


Шаблон:



Спиральный поиск

Спиральный поиск

Контр-пример: Если мы будем все время искать с какого-то края, то у нас будут «ползти» ровные куски кадра



Векторы-кандидаты

Вектора движения соседних блоков очень похожи


Идея: сформируем набор, состоящий из уже вычисленных векторов движения соседних блоков

В качестве вектора движения в каждом блоке будем выбирать лучший вектор из набора кандидатов

3D recursive search (3DRS)


1. Формируем набор векторов-кандидатов:
 - смещения $(-1, -1)$ и $(1, -1)$ в текущем кадре
 - смещения $(-2, 2)$, $(2, 2)$ в предыдущем кадре
2. В первые 2 вектора добавляем случайный вектор с амплитудой до ± 3 пикселей
3. Выбираем вектор с наименьшей SAD*

* SAD — сумма модулей разностей координат



Enhanced 3DRS (E3DRS)

Дополнительный
поиска вектора
с наилучшей SAD
по шаблону
«малый квадрат»
вокруг
выбранного вектора-
кандидата




Векторы движения

Вектора движения (1)

Кадр из фильма
«Кошки против собак»


Векторами показаны
распознанные вектора
движения блоков



Вектора движения (2)

Кадр из фильма
«Кошки против собак»
Следующий кадр

Показана межкадровая
разница, сравнительно
небольшая, благодаря
компенсации движения



Вектора движения (3)

Кадр из фильма
«Звездные войны,
Эпизод 1»


Векторами
показаны
распознанные
вектора движения
блоков



Вектора движения (4)



Кадр из фильма
«Звездные войны,
Эпизод 1»
Следующий кадр

Хорошо видно,
что хуже всего
распознался
«воротник
за логотипом»





Предсказания из статистики

Гистограмма
векторов на 11 кадре
последовательности
Suzi




Гистограмма
векторов на 12 кадре
последовательности
Suzi




Список векторов

Обработанный блок на кадре t 	Обработанный блок на кадре t 	Обработанный блок на кадре t 
Обработанный блок на кадре t 	Текущий блок для обработки 	Обработанный блок на кадре $t-1$ 
Обработанный блок на кадре $t-1$ 	Обработанный блок на кадре $t-1$ 	Обработанный блок на кадре $t-1$ 
Обработанный блок на кадре $t-1$ 	Обработанный блок на кадре $t-1$ 	Обработанный блок на кадре $t-1$ 

Схема для выбора векторов
в список кандидатов



кадр 34




кадр 35


Гистограммы векторов движения

движения (1)

Мультфильм (Рик и Морти)




Фильм (Мстители: Финал)




Гистограммы векторов движения (2)

Футбольный матч






Съемки природы с дрона




Субпиксельная точность предсказания блоков

Субпиксельная точность предсказания (1)



-  — границы пиксельной сетки
-  — границы полупиксельной сетки
-  — блок, найденный на пиксельной сетке
-  — лучший блок

Субпиксельная точность предсказания (2)




Разность в зависимости от размера блока



1 кадр



2 кадр




Разность между кадрами без
применения ME

Остаточный кадр при разном размера блока (1)




16x16 блок

Остаточный кадр при разном размера блока (2)



8x8 блок

Остаточный кадр при разном размера блока (3)



4x4 блок

Остаточный кадр при различной точности (4)



4x4 блок Half-pixel


Остаточный кадр при различной точности (5)



4x4 блок Quarter-pixel

Как качество зависит от точности?

Несжатые последовательности




<https://videoprocessing.ai/>


Оптический поток

Определение


Векторное поле явного движения объектов (пикселей), поверхностей и ребер в визуальной сцене между кадрами, вызванное относительным движением между наблюдателем (глазом, камерой) и сценой




Первый кадр



Второй кадр



Оптический поток



Оптический поток
(color coding)

Элементарное уравнение оптического потока

$$I(x+u, y+v) = I(x, y) + \frac{\partial I}{\partial x}u + \frac{\partial I}{\partial y}v,$$

$$I(x+u, y+v) - H(x, y) = 0;$$


$$I(x, y) + I_x u + I_y v - H(x, y) = 0;$$

$$[I(x, y) - H(x, y)] + I_x u + I_y v = 0;$$


$$I_t + I_x u + I_y v = 0;$$

$$I_t + \nabla I(uv) = 0.$$

Получаем одно уравнение с двумя
неизвестными, возникает неопределенность





$H(x, y)$



$I(x, y)$


Aperture problem

Куда двигаются линии?



Aperture problem

Куда двигаются линии?



Ответ: невозможно определить

Алгоритм Lucas-Kanade

- Используется для видео, содержащего кадры с обилием однородных областей
- Основан на предположении о том, что соседние пиксели смещаются в одном направлении (local motion constancy)
- Составляется система для n пикселей выбранного окна

$$\begin{cases} I'_x(p_1)u + I'_y(p_1)v = -I'_t(p_1) \\ I'_x(p_2)u + I'_y(p_2)v = -I'_t(p_2) \\ \dots \\ I'_x(p_n)u + I'_y(p_n)v = -I'_t(p_n) \end{cases} \quad A = \begin{bmatrix} I'_x(p_1) & I'_y(p_1) \\ I'_x(p_2) & I'_y(p_2) \\ \dots & \dots \\ I'_x(p_n) & I'_y(p_n) \end{bmatrix} \quad \gamma = \begin{bmatrix} dx \\ dy \end{bmatrix} \quad b = \begin{bmatrix} -I'_t(p_1)dt \\ -I'_t(p_2)dt \\ \dots \\ -I'_t(p_n)dt \end{bmatrix}$$

- Находим смещение γ методом наименьших квадратов:

$$A^T A \gamma = A^T b \Rightarrow (A^T A)^{-1} (A^T A) \gamma = (A^T A)^{-1} A^T b$$

$$\gamma = (A^T A)^{-1} A^T b$$

Вариационный подход и его модификации



Horn-Schunck:

$$E(u, v) = \int_{\Omega} (I_x u + I_y v + I_z)^2 + \alpha (|\nabla u|^2 + |\nabla v|^2) dx \rightarrow \min$$

Robust smoothness term (Cohen 1993, Schnörr 1994)

Non-linearized constancy (Nagel-Enkelmann 1986, Alvarez et al. 2000)

Gradient constancy (Brox et al. 2004)



Robust data term (Black-Anandan 1996, Mémin-Pérez 1996)

Spatiotemporal smoothness (Nagel 1990)


Финальная модель оптического потока:

$$E(u, v) = \int_{\Omega} \underbrace{\Psi \left(\underbrace{(I(x + u, y + v, t + 1) - I(x, y, t))^2}_{\text{data term}} \right)}_{\text{robust data term}} + \underbrace{\gamma |\nabla I(x + u, y + v, t + 1) - \nabla I(x, y, t)|^2}_{\text{robust smoothness term}} + \underbrace{\alpha \Psi (|\nabla_3 u|^2 + |\nabla_3 v|^2)}_{\text{spatiotemporal smoothness}} dx$$

Визуализация каждого улучшения



Ground truth




Spatiotemporal smoothness

Нейросетевые методы построения оптического потока

Модель для предсказания потока


FlowNet




Архитектура нейросети

Сужающаяся часть

FlowNetSimple



FlowNetCorr



**GRAPHICS & MEDIA LAB
VIDEO GROUP**




P. Fischer, A. Dosovitskiy, E. Ilg, P. Häusser, C. Hazırbas, V. Golkov
P. v.d. Smagt, D. Cremers, T. Brox


FlowNet: Learning Optical Flow with Convolutional Networks

Модель для предсказания потока

PWC-Net




Модель для предсказания потока RAFT



Обучающая выборка

Flying Chairs




- 964 изображения с Flickr в качестве фонов
- 809 3D-моделей стульев
- Движение: случайные аффинные преобразования фона и стульев
- Итого 22,872 пары изображений разрешения 512×384 с ground-truth OF

AutoFlow (1)

- Генерирует синтетический датасет, использующийся для предобучения моделей и оптимизированный под целевой датасет (в терминах визуальных искажений)
- Выбираются произвольные кадры и маски (в т.ч. для фона), к которым применяется случайный оптический поток

AutoFlow (2)

- Финальное изображение порождается их совмещением



Какой датасет лучше?

AutoFlow против FlyingChairs



Frame 29 of final Ambush.4



Ground truth




AutoFlow



FlyingChairs



Frame 000094 of KITTI training



Ground truth




AutoFlow



FlyingChairs



Frame 000104 of KITTI training



Ground truth



AutoFlow



FlyingChairs

Model	Dataset	Sintel.clean	Sintel.final	KITTI
PWC-Net	FlyingChairs	3.27	4.42	11.43
	Chairs → Things	2.39	3.90	9.81
	AutoFlow	2.17	2.91	5.76
RAFT	FlyingChairs	2.27	3.76	7.63
	Chairs → Things	1.68	2.80	5.92
	AutoFlow	1.95	2.57	4.23